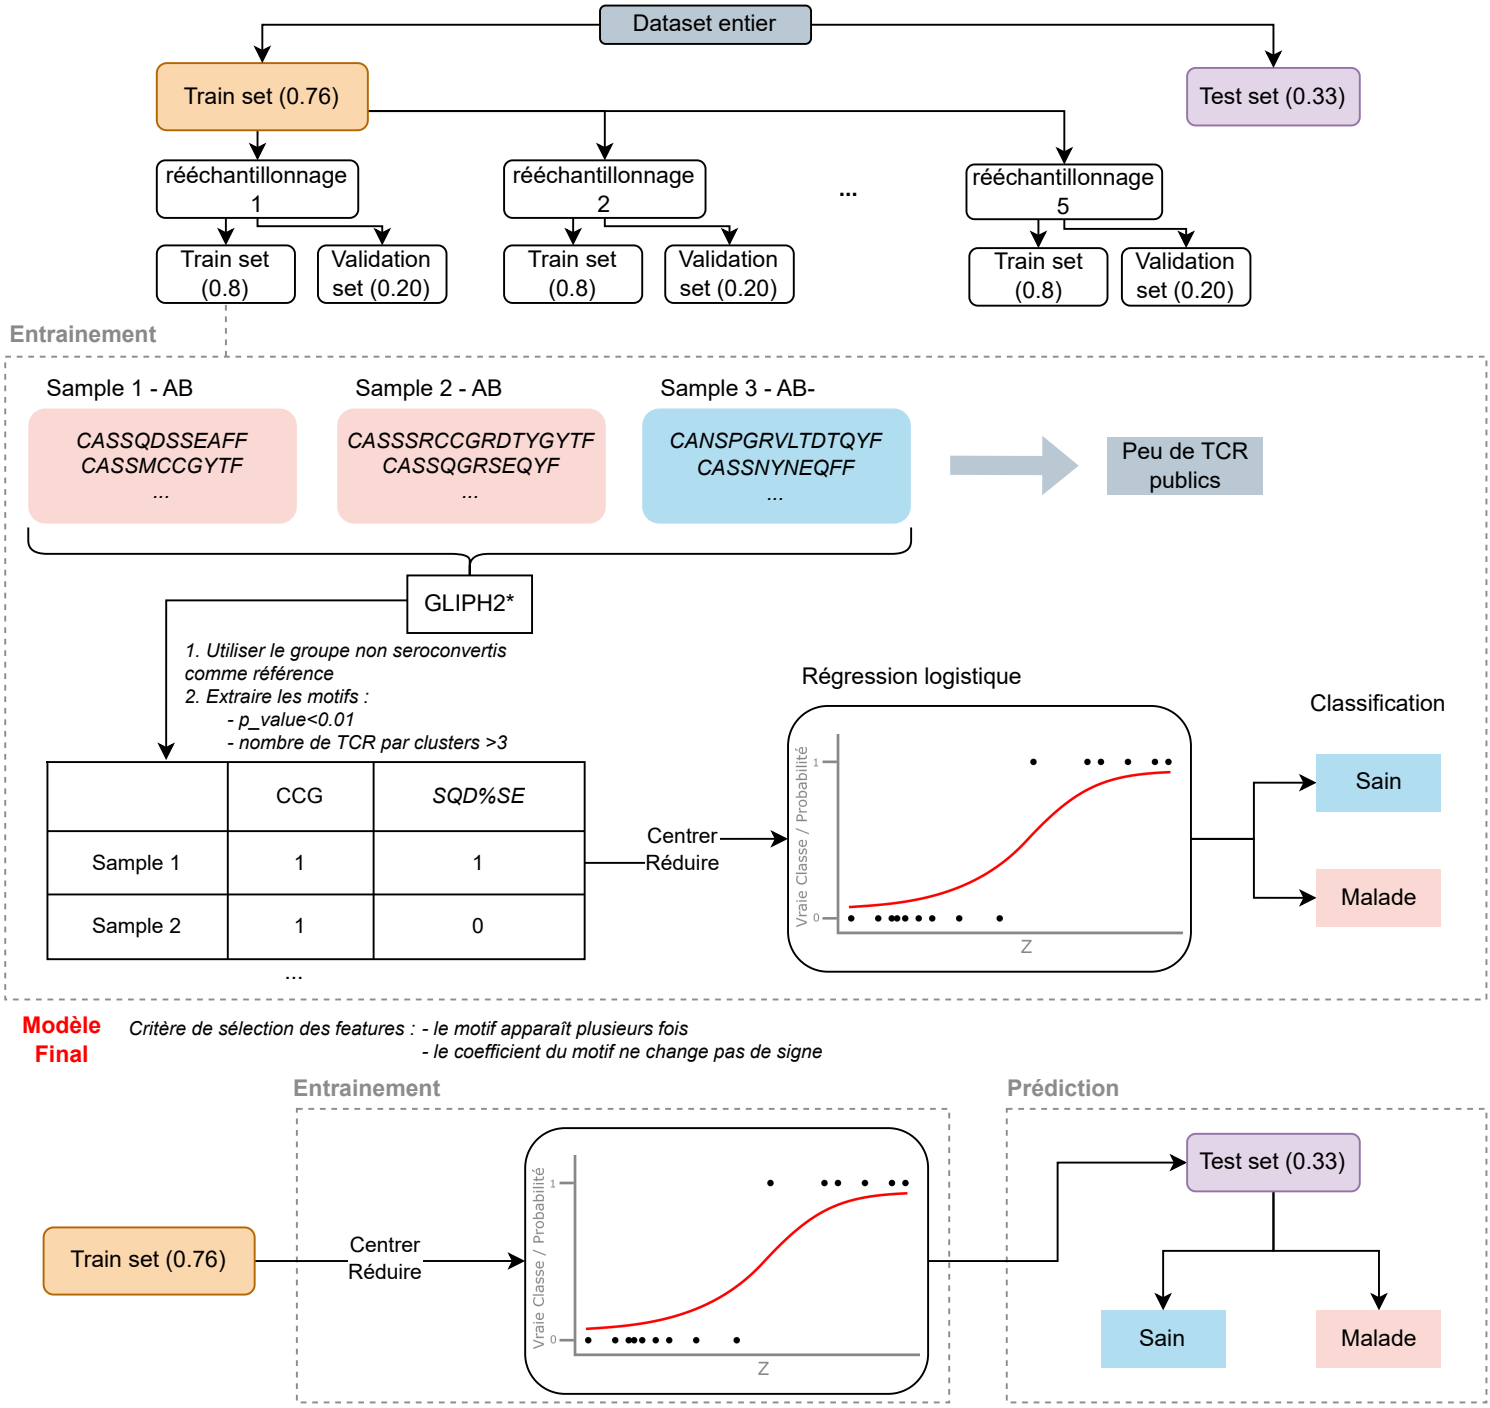

Dataset entier
Train set (0.76)
Test set (0.33)
rééchantillonnage 1
rééchantillonnage 2
...
rééchantillonnage 5
Train set (0.8)
Validation set (0.20)
Train set (0.8)
Validation set (0.20)
Train set (0.8)
Validation set (0.20)
Entrainement
Sample 1 - AB
CASSQDSSEAFF
CASSMCCGYTF
...
Sample 2 - AB
CASSSRCCGRDTYGYTF
CASSQGRSEQYF
...
Sample 3 - AB-
CANSPGRVLTDTQYF
CASSNYNEQFF
...
Peu de TCR publics
GLIPH2*
1. Utiliser le groupe non seroconvertis comme référence
2. Extraire les motifs :
- p_value<0.01
- nombre de TCR par clusters >3
CCG
SQD%SE
Sample 1
1
1
Sample 2
1
0
...
Centrer
Réduire
Régression logistique
Vraie Classe / Probabilité
Z
Classification
Sain
Malade
Modèle Final
Critère de sélection des features : - le motif apparaît plusieurs fois
- le coefficient du motif ne change pas de signe
Entrainement
Train set (0.76)
Centrer
Réduire
Vraie Classe / Probabilité
Z
Prédiction
Test set (0.33)
Sain
Malade